Music VAE를 통한 미디 생성

작성자 : 김재훈

논문리뷰

A Hierarchical Latent Vector Model for Learning Long-Term Structure in Music

Adam Roberts, Jesse Engel, Colin Raffel,
Curtis Hawthorne, Douglas Eck

❖논문 개요

- Latent vector 들을 차원에 적절하게 분포 시키기 위한 VAE 구조 사용

- 기존 RNN 사용시 긴 데이터 구조에서 발생되는 Vanishing Gradient 문제를 해결하기 위해 계층적 디코더를 제안함

- 제안된 아키텍쳐 적용을 통해 기존보다 Sampling, Interpolation, reconstruction 성능이 향상됨을 발견함

❖제안된 네트워크 구조

- 긴 마디의 멜로디 생성을 위한 네크워크 구조
- Encoder, Latent Code, Conductor, Decoder

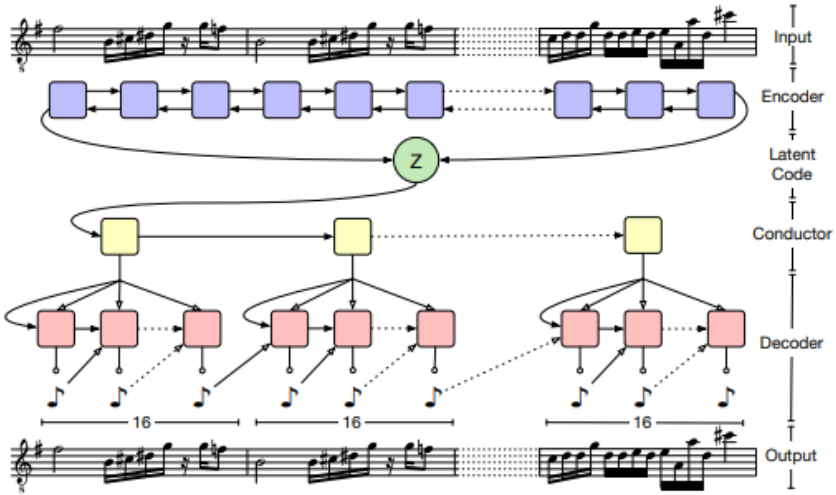

[논문에서 제안한 네트워크 구조]

```
CONFIG_MAP['hierdec-mel_16bar'] = Config(
    model=MusicVAE(
        lstm_models.BidirectionalLstmEncoder(),
        lstm_models.HierarchicalLstmDecoder(
            lstm_models.CategoricalLstmDecoder(),
            level_lengths=[16, 16],
            disable_autoregression=True)),
    hparams=merge_hparams(
        lstm_models.get_default_hparams(),
        HParams(
            batch_size=512,
            max_seq_len=256,
            z_size=512,
            enc_rnn_size=[2048, 2048],
            dec_rnn_size=[1024, 1024],
            free_bits=256,
            max_beta=0.2,
        )),
    note_sequence_augmenter=None,
    data_converter=mel_16bar_converter,
    train_examples_path=None,
    eval_examples_path=None,
)
```

[코드로 구현된 네트워크 구조와 파라미터]

❖제안된 네트워크 구조

▸ Encoder

- 2048 크기를 갖는 양방향 2 Layer-LSTM으로 구성
- 순방향 역방향에 대한 LSTM 네트워크 레이어를 각 2개씩 생성
- stack_bidirectional_dynamic_rnn을 통한 두개의 LSTM 레이어를 stacking
- 순방향과 역방향의 마지막 weight를 concatenate하여 출력값으로 보냄

```python
def build_bidirectional_lstm(
    layer_sizes, dropout_keep_prob, residual, is_training):
  """Build the Tensorflow graph for a bidirectional LSTM."""

  cells_fw = []
  cells_bw = []
  for layer_size in layer_sizes:
    cells_fw.append(
        rnn_cell([layer_size], dropout_keep_prob, residual, is_training))
    cells_bw.append(
        rnn_cell([layer_size], dropout_keep_prob, residual, is_training))

  return cells_fw, cells_bw
```

[양방향 LSTM 빌드 코드]

```python
def encode(self, sequence, sequence_length):
  cells_fw, cells_bw = self._cells

  _, states_fw, states_bw = contrib_rnn.stack_bidirectional_dynamic_rnn(
      cells_fw,
      cells_bw,
      sequence,
      sequence_length=sequence_length,
      time_major=False,
      dtype=tf.float32,
      scope=self._name_or_scope)
  # Note we access the outputs (h) from the states since the backward
  # ouputs are reversed to the input order in the returned outputs.
  last_h_fw = states_fw[-1][-1].h
  last_h_bw = states_bw[-1][-1].h

  return tf.concat([last_h_fw, last_h_bw], 1)
```

[양방향 LSTM을 활용한 인코더 코드]

❖제안된 네트워크 구조

▸ Latent Code

- Encoder의 출력과 Dense Layer를 활용한 Latent Vector를 생성

- Dense Layer와 softplus 활성함수를 통해 Encoder의 출력에 대한 시그마값을 생성

- Latent Vector의 확률분포와 MultiVariateNormalDiag에 의한 확률분포의 KL Divergence 계산을 통한 확률분포 차이 계산

```
def encode(self, sequence, sequence_length, control_sequence=None):
  """ """
  hparams = self.hparams
  z_size = hparams.z_size

  sequence = tf.to_float(sequence)
  if control_sequence is not None:
    control_sequence = tf.to_float(control_sequence)
    sequence = tf.concat([sequence, control_sequence], axis=-1)
  encoder_output = self.encoder.encode(sequence, sequence_length)

  mu = tf.layers.dense(
      encoder_output,
      z_size,
      name='encoder/mu',
      kernel_initializer=tf.random_normal_initializer(stddev=0.001))
  sigma = tf.layers.dense(
      encoder_output,
      z_size,
      activation=tf.nn.softplus,
      name='encoder/sigma',
      kernel_initializer=tf.random_normal_initializer(stddev=0.001))

  return ds.MultivariateNormalDiag(loc=mu, scale_diag=sigma)
```

[Latent Vector 생성 코드]

```
if hparams.z_size:  # vae mode:
  q_z = self.encode(input_sequence, x_length, control_sequence)
  z = q_z.sample()

  # Prior distribution.
  p_z = ds.MultivariateNormalDiag(
      loc=[0.] * hparams.z_size, scale_diag=[1.] * hparams.z_size)

  # KL Divergence (nats)
  kl_div = ds.kl_divergence(q_z, p_z)
```

[KL Divergence 계산 코드]

❖제안된 네트워크 구조

▸ Hierarchical Decoder (Conductor, Decoder)

- Conductor : 512인풋의 1024출력을 가지는 단방향 LSTM 레이어로 구성
  Latent vector를 입력으로 가지지만 학습시에는 Latent vector를 0으로 초기화하여 재귀적으로 업데이트함
- Decoder : 1024 크기를 갖는 단방향 2 Layer-LSTM으로 구성

```
def build(self, hparams, output_depth, is_training=True):
  self.hparams = hparams
  self._output_depth = output_depth
  self._total_length = hparams.max_seq_len
  if self._total_length != np.prod(self._level_lengths):
    raise ValueError(
        'The product of the HierarchicalLstmDecoder level lengths (%d) must '
        'equal the padded input sequence length (%d).' % (
            np.prod(self._level_lengths), self._total_length))
  tf.logging.info('\nHierarchical Decoder:\n'
                  '  input length: %d\n'
                  '  level output lengths: %s\n',
                  self._total_length,
                  self._level_lengths)

  self._hier_cells = [
      lstm_utils.rnn_cell(
          hparams.dec_rnn_size,
          dropout_keep_prob=hparams.dropout_keep_prob,
          residual=hparams.residual_decoder)
      # Subtract 1 for the core decoder level
      for _ in range(len(self._level_lengths) - 1)]

  with tf.variable_scope('core_decoder', reuse=tf.AUTO_REUSE):
    self._core_decoder.build(hparams, output_depth, is_training)
```

[Hierarchical Decoder 빌드 코드]

```
def recursive_decode(initial_input, path=None):
  """Recursive hierarchical decode function."""
  path = path or []
  level = len(path)

  if level == num_levels:
    with tf.variable_scope('core_decoder', reuse=tf.AUTO_REUSE):
      return base_decode_fn(initial_input, path)

  scope = tf.VariableScope(tf.AUTO_REUSE, 'decoder/hierarchical_level_%d' % level)

  num_steps = self._level_lengths[level]

  with tf.variable_scope(scope):
    state = lstm_utils.initial_cell_state_from_embedding(
        self._hier_cells[level], initial_input, name='initial_state')
```

[Conductor 초기화 코드]

❖제안된 네트워크 구조

▸ 최종 Loss 계산

- Decoder의 결과와 Endoder의 결과를 통한 최종 Loss 산출

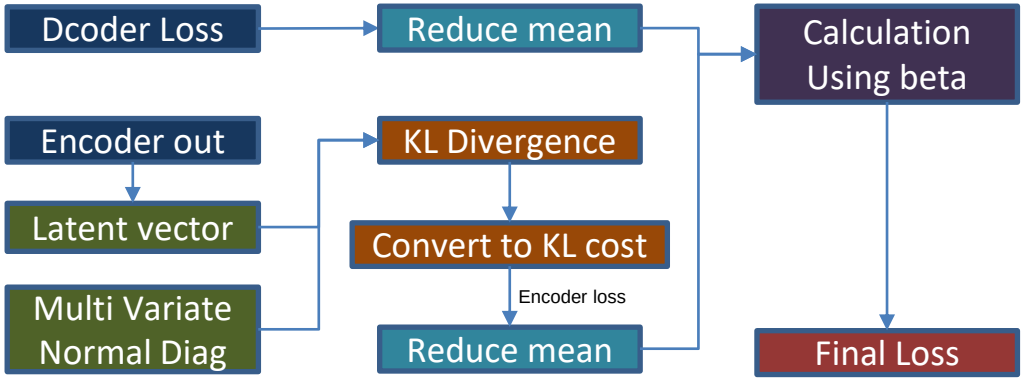

[최종 Loss 계산 도식]

```
if hparams.z_size:  # vae mode:
  q_z = self.encode(input_sequence, x_length, control_sequence)
  z = q_z.sample()

  # Prior distribution.
  p_z = ds.MultivariateNormalDiag(
      loc=[0.] * hparams.z_size, scale_diag=[1.] * hparams.z_size)

  # KL Divergence (nats)
  kl_div = ds.kl_divergence(q_z, p_z)

  # Concatenate the Z vectors to the inputs at each time step.
else:  # unconditional, decoder-only generation

r_loss, metric_map = self.decoder.reconstruction_loss(
    x_input, x_target, x_length, z, control_sequence)[0:2]

free_nats = hparams.free_bits * tf.math.log(2.0)
kl_cost = tf.maximum(kl_div - free_nats, 0)

beta = ((1.0 - tf.pow(hparams.beta_rate, tf.to_float(self.global_step)))
        * hparams.max_beta)
self.loss = tf.reduce_mean(r_loss) + beta * tf.reduce_mean(kl_cost)

scalars_to_summarize = {
    'loss': self.loss,
    'losses/r_loss': r_loss,
    'losses/kl_loss': kl_cost,
    'losses/kl_bits': kl_div / tf.math.log(2.0),
    'losses/kl_beta': beta,
}
return metric_map, scalars_to_summarize
```

[최종 Loss 계산 코드]

❖제안된 네트워크의 실험 결과

▸ 실험결과

- 긴 데이터 생성시 확실한 성능 향상을 보여주며, 생성된 파일의 음악적인 뉘양스도 향상된것을 확인할 수 있음

Model	Teacher-Forcing		Sampling	
	Flat	Hierarchical	Flat	Hierarchical
2-bar Drum	0.979	-	0.917	-
2-bar Melody	0.986	-	0.951	-
16-bar Melody	0.883	**0.919**	0.620	**0.812**
16-bar Drum	0.884	**0.928**	0.549	**0.879**
Trio (Melody)	0.796	**0.848**	0.579	**0.753**
Trio (Bass)	0.829	**0.880**	0.565	**0.773**
Trio (Drums)	0.903	**0.912**	0.641	**0.863**

[제안된 네트워크를 활용한 실험 결과]

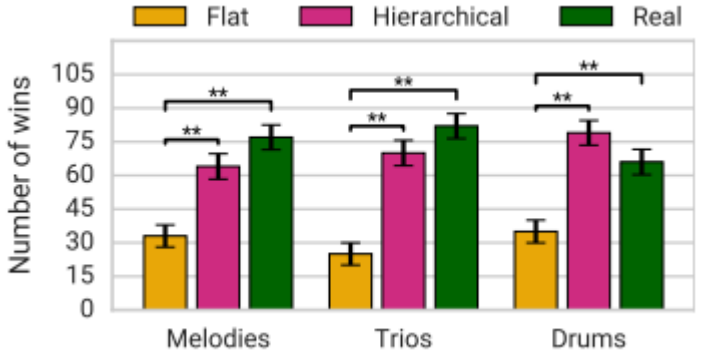

[청취자를 통한 음악성 실험 결과]

과 제 구 현

❖과제 목표

- 논문에서 제안한 아키텍쳐인 Hierarchical Latent Vector Model 구조를 활용한 MusicVAE와 Groove MIDI Dataset을 활용하여 4마디에 해당하는 드럼샘플을 뽑아내는 과정을 수행하는 것

❖실험 환경

- CPU : INTEL CORE i9 - 12900K
- GPU : Geforce RTX 2080TI X 1EA
- RAM : 32GB RAM
- OS : Ubuntu 18.04

❖실험 모델 구성

- MusicVAE 모델을 활용한 드럼샘플 생성기
- GrooVAE 모델을 활용한 드럼샘플 생성기
- MusicVAE 모델을 활용한 피아노샘플 생성기
- 실험 결과에 따른 개선 모델

❖ 실험 데이터 구성

- 사용 데이터 셋 : Groove MIDI Dataset
- 데이터 형식 : MIDI
- 총 파일 개수 : 1,150개
- 총 파일 시간 : 약 814분 분량
- 곡 스타일 : 18개의 대분류 스타일로 구성
- 비트 타입 : 2가지로 구성 (Beat, Fill)

❖데이터 구조

- MIDI 데이터의 구조

  - 곡의 템포 정보 및 악기 정보가 포함됨

  - 각 노트의 발생 여부, 피치, 세기, 시작 및 끝 시간 등의 정보가 포함됨

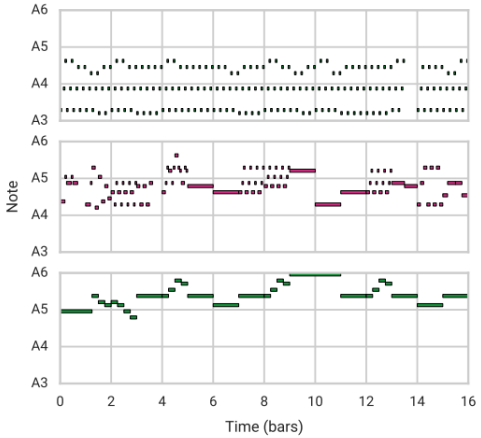

[논문에서의 미디 파일 표기]

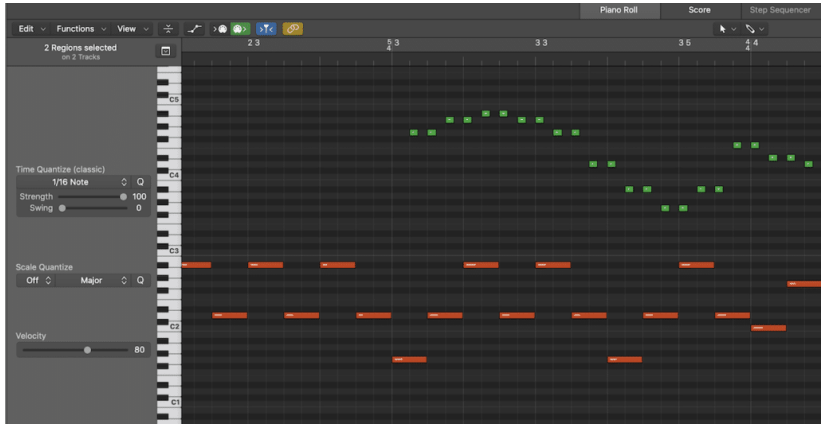

[DAW에서의 미디파일을 불러왔을 때의 예]

❖데이터 전처리

▸ MIDI 데이터 전처리 과정 - 1

- MIDI 파일을 스트링 시퀀스로 컨버팅하여 Tfrecord로 저장

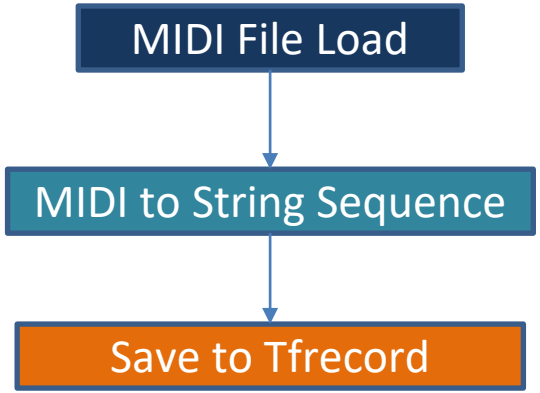

[MIDI to String 컨버팅 과정]

```
tempos {
  qpm: 100.0
}
notes {
  pitch: 22
  velocity: 113
  start_time: 0.01625
  end_time: 0.11750000000000001
  is_drum: true
}
notes {
  pitch: 36
  velocity: 65
  start_time: 0.01625
  end_time: 0.11750000000000001
  is_drum: true
}
```

[미디 파일을 스트링 시퀀스로 컨버팅한 예]

❖데이터 전처리

▸ MIDI 데이터 전처리 과정 - 2

- GrooveConverter 사용
- String Sequence를 Tensor Vector로 컨버팅
- 컨버팅 과정 (data.py의 GrooveConverter클래스를 참조함)

1. REDUCED_DRUM_PITCH_CLASSES 옵션을 사용하였기 때문에 9개의 클래스 사용 (kick, snare, closed_hh, open_hh, low_tom, mid_tom, hi_tom, crash, ride)
2. 마디당 16개의 노트와 각 노트당 9개의 클래스로 구성된 스페이스를 사용
3. 피치 정보는 각 9개 클래스에 fit하게 재 맵핑
4. Note 발생 여부를 0 또는 1로 구성 -> Shape(16, 9)
5. Velocity의 경우 0~127 -> 0~1 사이의 구성으로 노멀라이즈 -> Shape(16, 9)
6. Offsets의경우 발생 노트의 시작타임을 퀀타이제이션하여 제일 가까운 마디로 마디를 맞추고 -0.5 ~ 0.5 -> -1 ~ 1로 리스케일링을 진행함 -> Shape(16, 9)
7. Note 여부, Velocity, Offset을 Concatenate하여 최종 Vector로 구성 -> Shape(16, 27)

❖데이터 전처리

▸ MIDI 데이터 전처리 과정 도식

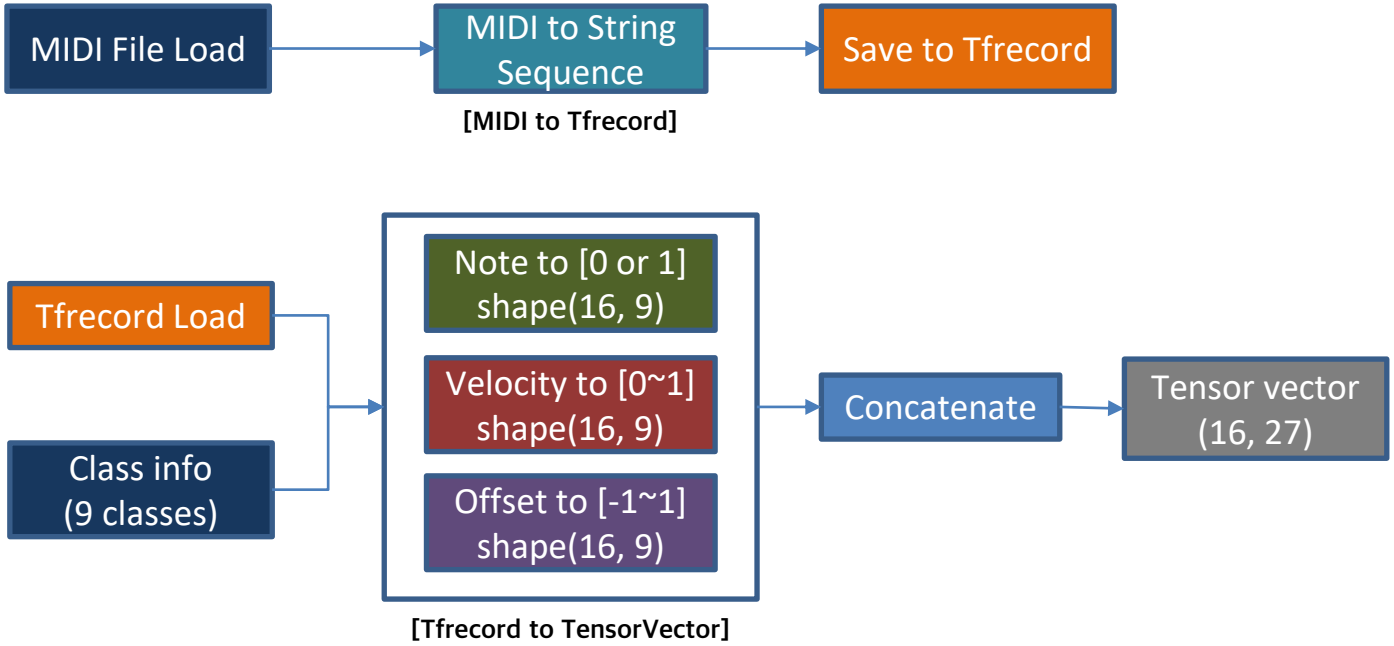

❖데이터 생성

▸ 학습된 모델을 활용한 MIDI 데이터 생성 과정 - 1

- MIDI To TensorVector와 정반대의 진행과정
- Tensor Vector Result를 String Sequence로 컨버팅 및 MIDI 파일 생성
- 컨버팅 과정 (data.py의 GrooveConverter클래스를 참조함)

1. 학습된 모델의 결과로 발생되는 Tensor Vector Result -> Shape (16, 27)
2. 결과에 따른 Timesteps, Tempo, 비트길이, 스텝길이 생성 (Tempo는 120으로 고정됨)
3. 결과 텐서를 각각 Hit, Velocity, Offsets으로 분리 -> Shape (16, 9) 3개로 분리됨
4. Velocity의 경우 0~127로 리스케일링
5. Offset의 경우 -0.5~0.5로 리스케일링하여 시작시간과 끝시간을 계산함, 끝시간은 시작시간 + 스텝길이로 계산함
6. 9개의 클래스 결과를 MIDI Pitch로 리맵핑 진행
7. Hit의 결과가 0.5 이상의 경우 Note Sequence에 Note를 추가하며, Velocity, Offset, Pitch정보를 같이 저장

❖데이터 생성

- 학습된 모델을 활용한 MIDI 데이터 생성 과정 - 2

  - 스트링 시퀀스를 MIDI 파일로 컨버팅하여 저장

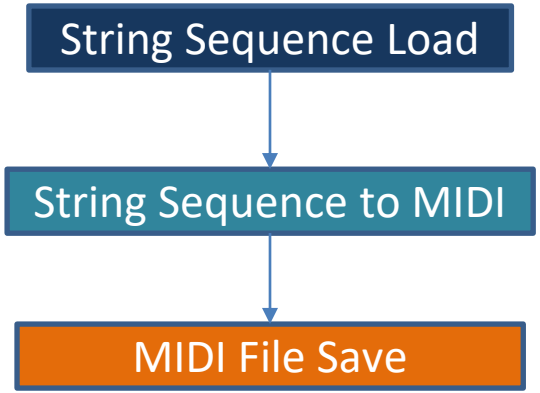

[String to MIDI 컨버팅 과정]

❖데이터 생성

- 학습된 모델을 활용한 MIDI 데이터 생성 과정 도식

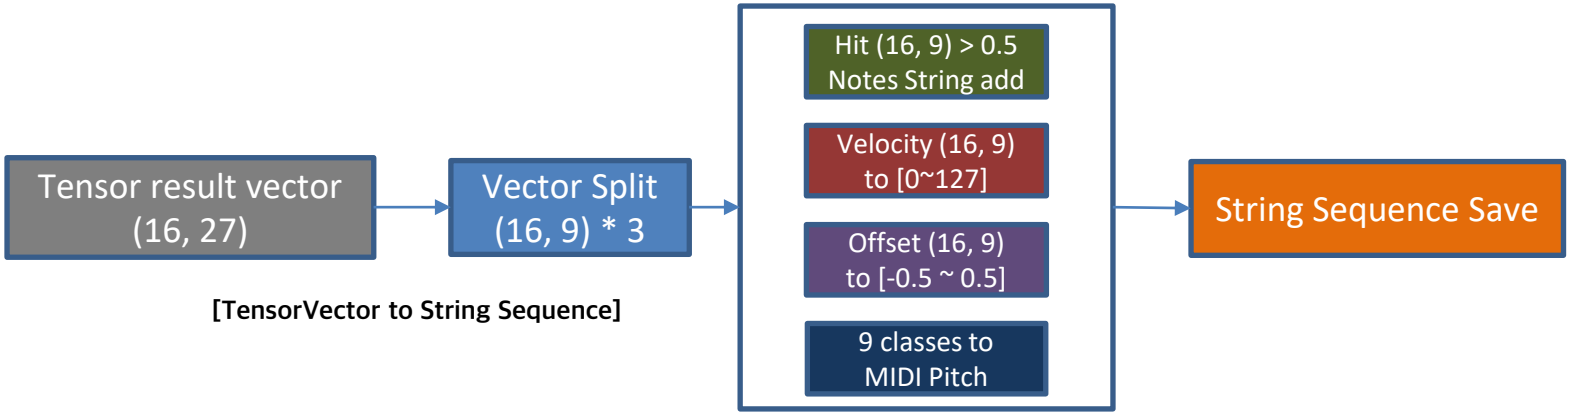

[TensorVector to String Sequence]

[String Sequence to MIDI File]

❖ MusicVAE 모델을 활용한 드럼샘플 생성기

▸ 모델 구성

- 논문에서 제안한 Hierarchical LSTM Decoder을 사용함

- 논문에서 요구하는 하이퍼 파라미터를 적용하여 학습시 OOM문제 발생

- 따라서 GrooVAE 하이퍼 파라미터 구성을 참조, 파라미터를 재조정하여 학습함

```
CONFIG_MAP['musicvae_4bar_paper_org'] = Config(
    model=MusicVAE(lstm_models.BidirectionalLstmEncoder(),
                   lstm_models.HierarchicalLstmDecoder(
                   core_decoder = lstm_models.CategoricalLstmDecoder(),
                   level_lengths=[16, 16],
                   disable_autoregression=True)),
    hparams=merge_hparams(
        lstm_models.get_default_hparams(),
        HParams(
            batch_size=512,
            max_seq_len= 256,  # 4 bars w/ 16 steps per bar  ### 256
            z_size=512,
            enc_rnn_size=[2048, 2048],    ### 2048, 2048
            dec_rnn_size=[1024, 1024],    ### 1024, 1024
            max_beta=0.2,
            free_bits=256,   ### 256
        )),
    note_sequence_augmenter=None,
    data_converter=data.GrooveConverter(
        split_bars=4, steps_per_quarter=4, quarters_per_bar=4,
        max_tensors_per_notesequence=20,
        pitch_classes=data.ROLAND_DRUM_PITCH_CLASSES,
        inference_pitch_classes=data.REDUCED_DRUM_PITCH_CLASSES),
    tfds_name='groove/groovae_4bar_paper',
)
```

[논문에서 명시된 하이퍼 파라미터 적용모델]

```
CONFIG_MAP['musicvae_4bar_paper_reduceunit'] = Config(
    model=MusicVAE(lstm_models.BidirectionalLstmEncoder(),
                   lstm_models.HierarchicalLstmDecoder(
                   core_decoder = lstm_models.CategoricalLstmDecoder(),
                   level_lengths=[8, 8],
                   disable_autoregression=True)),
    hparams=merge_hparams(
        lstm_models.get_default_hparams(),
        HParams(
            batch_size=512,
            max_seq_len= 16 * 4,  # 4 bars w/ 16 steps per bar  ### 256
            z_size=256,
            enc_rnn_size=[512],    ### 2048, 2048
            dec_rnn_size=[256, 256],    ### 1024, 1024
            max_beta=0.2,
            free_bits=48,   ### 256
        )),
    note_sequence_augmenter=None,
    data_converter=data.GrooveConverter(
        split_bars=4, steps_per_quarter=4, quarters_per_bar=4,
        max_tensors_per_notesequence=20,
        pitch_classes=data.ROLAND_DRUM_PITCH_CLASSES,
        inference_pitch_classes=data.REDUCED_DRUM_PITCH_CLASSES),
    tfds_name='groove/groovae_4bar_paper',
)
```

[하이퍼 파라미터 조절 후의 모델]

❖ MusicVAE 모델을 활용한 드럼샘플 생성기

▸ 모델 학습 결과 (Loss)

- Loss가 정상적으로 수렴하지 않는 현상이 발생함

```
2022-12-08 19:37:45.499785  {'global_step': 1500, 'loss': 404.56555}
2022-12-08 19:38:16.078867  {'global_step': 1600, 'loss': 433.5907}
2022-12-08 19:38:41.952162  {'global_step': 1700, 'loss': 423.32022}
2022-12-08 19:39:12.814201  {'global_step': 1800, 'loss': 406.69147}
2022-12-08 19:39:38.184088  {'global_step': 1900, 'loss': 420.4788}
2022-12-08 19:40:08.420905  {'global_step': 2000, 'loss': 397.63693}
2022-12-08 19:40:34.406170  {'global_step': 2100, 'loss': 453.93857}
2022-12-08 19:41:05.136708  {'global_step': 2200, 'loss': 442.0014}
2022-12-08 19:41:31.138173  {'global_step': 2300, 'loss': 395.34402}
2022-12-08 19:42:01.856173  {'global_step': 2400, 'loss': 427.68744}
2022-12-08 19:42:27.639652  {'global_step': 2500, 'loss': 404.72083}
2022-12-08 19:42:57.671283  {'global_step': 2600, 'loss': 440.6816}
2022-12-08 19:43:23.177979  {'global_step': 2700, 'loss': 441.5909}
2022-12-08 19:43:53.550373  {'global_step': 2800, 'loss': 412.12387}
2022-12-08 19:44:19.237989  {'global_step': 2900, 'loss': 446.85895}
2022-12-08 19:44:45.189608  {'global_step': 3000, 'loss': 427.8056}
2022-12-08 19:45:15.514716  {'global_step': 3100, 'loss': 445.20685}
2022-12-08 19:45:41.206355  {'global_step': 3200, 'loss': 434.45682}
```

[학습간 Loss 결과 로그]

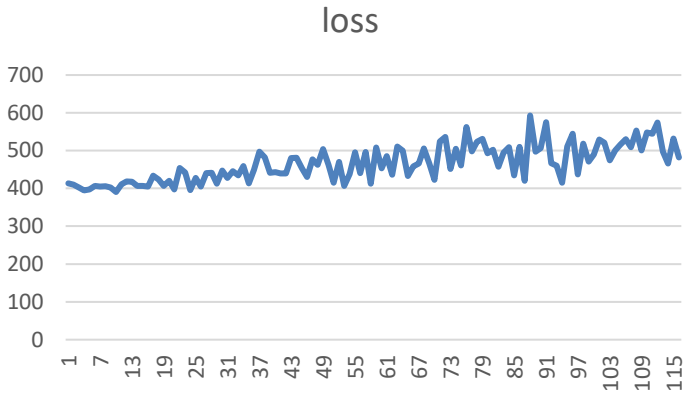

[학습간 Loss 결과 그래프]

❖MusicVAE 모델을 활용한 드럼샘플 생성기

▸ 모델 학습 결과 (MIDI 생성 및 재생)

- 정상적으로 미디파일이 생성되었으며, DAW에 정상적으로 로드 하였으나 4마디 드럼샘플이 제대로 생성되지 않은 것을 확인함

musicvae_4bar_paper_reduceunit_sample_2022-12-08_205626-000-of-005.mid
musicvae_4bar_paper_reduceunit_sample_2022-12-08_205626-001-of-005.mid
musicvae_4bar_paper_reduceunit_sample_2022-12-08_205626-002-of-005.mid
musicvae_4bar_paper_reduceunit_sample_2022-12-08_205626-003-of-005.mid
musicvae_4bar_paper_reduceunit_sample_2022-12-08_205626-004-of-005.mid

[생성된 MIDI파일 리스트]

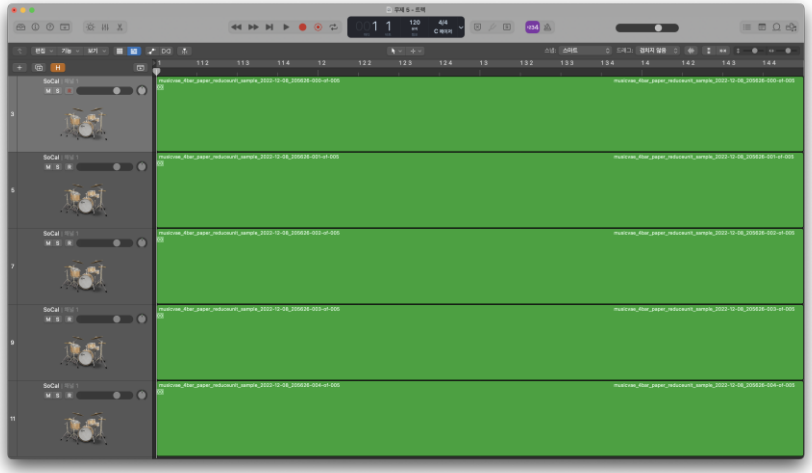

[DAW에서의 MIDI파일 로드]

❖GrooVAE 모델을 활용한 드럼샘플 생성기

▸ 모델 구성

- HierarchicalLstmDecoder 구성이 GrooveLstmDecoder로 변경되었으며, Dropout이 추가됨

- 하이퍼 파라미터의 경우 이전 실험과 최대한 동일하게 적용하여 학습 진행

```
CONFIG_MAP['musicvae_4bar_paper_reduceunit'] = Config(
    model=MusicVAE(lstm_models.BidirectionalLstmEncoder(),
                   lstm_models.HierarchicalLstmDecoder(
                   core_decoder = lstm_models.CategoricalLstmDecoder(),
                   level_lengths=[8, 8],
                   disable_autoregression=True)),
    hparams=merge_hparams(
        lstm_models.get_default_hparams(),
        HParams(
            batch_size=512,
            max_seq_len= 16 * 4,  # 4 bars w/ 16 steps per bar  ### 256
            z_size=256,
            enc_rnn_size=[512],    ### 2048, 2048
            dec_rnn_size=[256, 256],    ### 1024, 1024
            max_beta=0.2,
            free_bits=48,   ### 256
        )),
    note_sequence_augmenter=None,
    data_converter=data.GrooveConverter(
        split_bars=4, steps_per_quarter=4, quarters_per_bar=4,
        max_tensors_per_notesequence=20,
        pitch_classes=data.ROLAND_DRUM_PITCH_CLASSES,
        inference_pitch_classes=data.REDUCED_DRUM_PITCH_CLASSES),
    tfds_name='groove/groovae_4bar_paper',
)
```

[실험용 MusicVAE 모델]

```
CONFIG_MAP['groovae_4bar'] = Config(
    model=MusicVAE(lstm_models.BidirectionalLstmEncoder(),
                   lstm_models.GrooveLstmDecoder()),
    hparams=merge_hparams(
        lstm_models.get_default_hparams(),
        HParams(
            batch_size=512,
            max_seq_len=16 * 4,  # 4 bars w/ 16 steps per bar
            z_size=256,
            enc_rnn_size=[512],
            dec_rnn_size=[256, 256],
            max_beta=0.2,
            free_bits=48,
            dropout_keep_prob=0.3,
        )),
    note_sequence_augmenter=None,
    data_converter=data.GrooveConverter(
        split_bars=4, steps_per_quarter=4, quarters_per_bar=4,
        max_tensors_per_notesequence=20,
        pitch_classes=data.ROLAND_DRUM_PITCH_CLASSES,
        inference_pitch_classes=data.REDUCED_DRUM_PITCH_CLASSES),
    tfds_name='groove/4bar-midionly',
)
```

[GrooVAE 모델]

❖GrooVAE 모델을 활용한 드럼샘플 생성기

▸ 모델 학습 결과 (Loss)

- Loss가 적절히 수렴하는 그래프를 보임

```
2022-12-08 21:38:08.696601  {'global_step': 26700, 'loss': 45.156902}
2022-12-08 21:38:25.598927  {'global_step': 26800, 'loss': 45.022232}
2022-12-08 21:38:41.906256  {'global_step': 26900, 'loss': 45.54123}
2022-12-08 21:38:58.036237  {'global_step': 27000, 'loss': 46.0045}
2022-12-08 21:39:15.090613  {'global_step': 27100, 'loss': 44.75186}
2022-12-08 21:39:31.136044  {'global_step': 27200, 'loss': 44.045895}
2022-12-08 21:39:47.150473  {'global_step': 27300, 'loss': 46.870502}
2022-12-08 21:40:03.310964  {'global_step': 27400, 'loss': 46.0117}
2022-12-08 21:40:20.294549  {'global_step': 27500, 'loss': 43.349464}
2022-12-08 21:40:36.579751  {'global_step': 27600, 'loss': 44.245388}
2022-12-08 21:40:52.775200  {'global_step': 27700, 'loss': 43.594513}
2022-12-08 21:41:08.845664  {'global_step': 27800, 'loss': 43.92478}
2022-12-08 21:41:25.790991  {'global_step': 27900, 'loss': 42.92893}
2022-12-08 21:41:41.807794  {'global_step': 28000, 'loss': 43.23259}
2022-12-08 21:41:57.792563  {'global_step': 28100, 'loss': 45.258076}
2022-12-08 21:42:14.715215  {'global_step': 28200, 'loss': 45.0357}
2022-12-08 21:42:30.777812  {'global_step': 28300, 'loss': 45.65116}
2022-12-08 21:42:46.880809  {'global_step': 28400, 'loss': 44.540585}
2022-12-08 21:43:02.935018  {'global_step': 28500, 'loss': 43.96586}
2022-12-08 21:43:19.997351  {'global_step': 28600, 'loss': 42.42533}
```

[학습간 Loss 결과 로그]

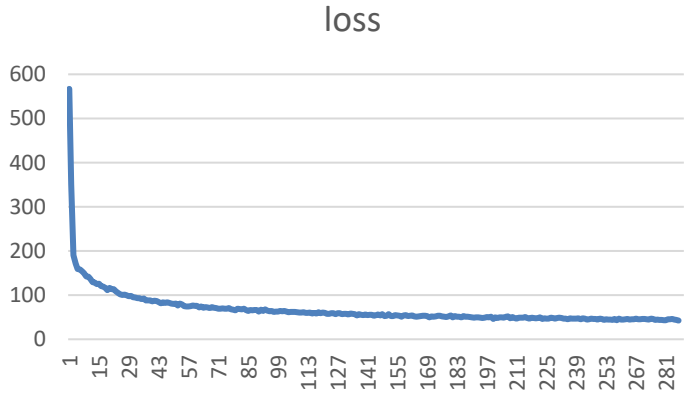

[학습간 Loss 결과 그래프]

❖GrooVAE 모델을 활용한 드럼샘플 생성기

▸ 모델 학습 결과 (MIDI 생성 및 재생)

- 정상적으로 미디파일이 생성되었으며, DAW에 로드 및 재생하여 4마디 드럼샘플이 제대로 생성되는 것을 확인함

groovae_4bar_sample_2022-12-08_215155-000-of-005.mid
groovae_4bar_sample_2022-12-08_215155-001-of-005.mid
groovae_4bar_sample_2022-12-08_215155-002-of-005.mid
groovae_4bar_sample_2022-12-08_215155-003-of-005.mid
groovae_4bar_sample_2022-12-08_215155-004-of-005.mid

[생성된 MIDI파일 리스트]

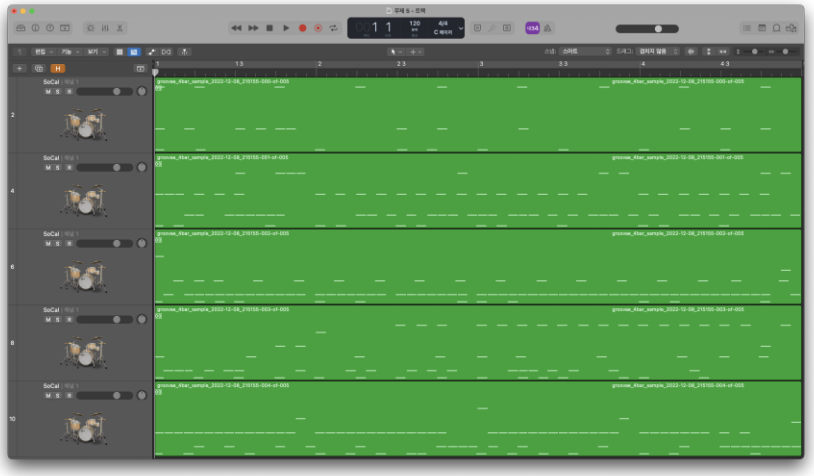

[DAW에서의 MIDI파일 로드]

❖ MusicVAE 모델을 활용한 피아노샘플 생성기

▸ 개요

- 논문에서 제안한 모델이 Groove Dataset에서 좋지 않은 성능을 보여줌
- 성능 저하의 원인 파악을 위해 위해 동일한 파라미터로 4마디 피아노 멜로디 생성 실험을 진행함
- Groove데이터셋과 비슷한 양의 데이터를 구성하여 실험 진행

▸ 실험 데이터 구성

- 사용 데이터 셋 : Maestro v3.0.0 Dataset 2015
- 데이터 형식 : MIDI
- 총 파일 개수 : 129개
- 총 파일 시간 : 857분 분량

```
CONFIG_MAP['musicvae_4bar_paper_reduceunit'] = Config(
    model=MusicVAE(lstm_models.BidirectionalLstmEncoder(),
                   lstm_models.HierarchicalLstmDecoder(
                   core_decoder = lstm_models.CategoricalLstmDecoder(),
                   level_lengths=[8, 8],
                   disable_autoregression=True)),
    hparams=merge_hparams(
        lstm_models.get_default_hparams(),
        HParams(
            batch_size=512,
            max_seq_len= 16 * 4,  # 4 bars w/ 16 steps per bar  ### 256
            z_size=256,
            enc_rnn_size=[512],    ### 2048, 2048
            dec_rnn_size=[256, 256],    ### 1024, 1024
            max_beta=0.2,
            free_bits=48,   ### 256
        )),
    note_sequence_augmenter=None,
    data_converter=data.GrooveConverter(
        split_bars=4, steps_per_quarter=4, quarters_per_bar=4,
        max_tensors_per_notesequence=20,
        pitch_classes=data.ROLAND_DRUM_PITCH_CLASSES,
        inference_pitch_classes=data.REDUCED_DRUM_PITCH_CLASSES),
    tfds_name='groove/groovae_4bar_paper',
)
```

[Groove Data 활용 모델 구성]

```
mel_4bar_converter = data.OneHotMelodyConverter(
    skip_polyphony=False,
    max_bars=100,  # Truncate long melodies before slicing.
    slice_bars=4,
    steps_per_quarter=4)

CONFIG_MAP['hierdec-mel_4bar'] = Config(
    model=MusicVAE(
        lstm_models.BidirectionalLstmEncoder(),
        lstm_models.HierarchicalLstmDecoder(
            lstm_models.CategoricalLstmDecoder(),
            level_lengths=[8, 8],
            disable_autoregression=True)),
    hparams=merge_hparams(
        lstm_models.get_default_hparams(),
        HParams(
            batch_size=512,
            max_seq_len=4 * 16,
            z_size=256,
            enc_rnn_size=[512],
            dec_rnn_size=[256, 256],
            free_bits=48,
            max_beta=0.2,
        )),
    note_sequence_augmenter=None,
    data_converter=mel_4bar_converter,
    train_examples_path=None,
    eval_examples_path=None,
)
```

[Maestro Data 활용 모델 구성]

❖ MusicVAE 모델을 활용한 피아노샘플 생성기

▸ 모델 학습 결과 (Loss)

- Groove 데이터 실험때와 동일한 파라미터임에도 불구하고 Loss가 빠르게 수렴하는 모습을 보임

```
2022-12-09 01:23:34.772502  {'global_step': 1300, 'loss': 25.372885}
2022-12-09 01:24:00.382810  {'global_step': 1400, 'loss': 17.933247}
2022-12-09 01:24:26.091646  {'global_step': 1500, 'loss': 11.584067}
2022-12-09 01:24:56.636984  {'global_step': 1600, 'loss': 7.661615}
2022-12-09 01:25:22.156637  {'global_step': 1700, 'loss': 4.5177584}
2022-12-09 01:25:52.515166  {'global_step': 1800, 'loss': 3.077307}
2022-12-09 01:26:17.909475  {'global_step': 1900, 'loss': 2.3420713}
2022-12-09 01:26:48.057723  {'global_step': 2000, 'loss': 1.1190193}
2022-12-09 01:27:13.771985  {'global_step': 2100, 'loss': 1.6619911}
2022-12-09 01:27:44.286829  {'global_step': 2200, 'loss': 0.57212454}
2022-12-09 01:28:09.735194  {'global_step': 2300, 'loss': 0.593472}
2022-12-09 01:28:40.178178  {'global_step': 2400, 'loss': 0.39969653}
2022-12-09 01:29:05.794799  {'global_step': 2500, 'loss': 0.4452215}
2022-12-09 01:29:35.901383  {'global_step': 2600, 'loss': 0.33789277}
2022-12-09 01:30:01.506219  {'global_step': 2700, 'loss': 0.21799786}
2022-12-09 01:30:27.105100  {'global_step': 2800, 'loss': 0.23725453}
2022-12-09 01:30:57.735892  {'global_step': 2900, 'loss': 0.6474892}
2022-12-09 01:31:23.544674  {'global_step': 3000, 'loss': 0.24804246}
2022-12-09 01:31:53.807016  {'global_step': 3100, 'loss': 0.10720755}
2022-12-09 01:32:19.188726  {'global_step': 3200, 'loss': 0.14033175}
2022-12-09 01:32:49.182710  {'global_step': 3300, 'loss': 0.12702069}
```

[학습간 Loss 결과 로그]

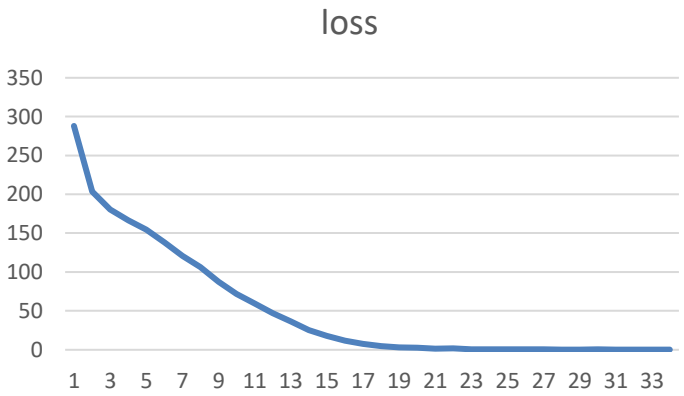

[학습간 Loss 결과 그래프]

❖ MusicVAE 모델을 활용한 피아노샘플 생성기

▸ 모델 학습 결과 (MIDI 생성 및 재생)

- 정상적으로 미디파일이 생성되었으며, DAW에 로드 및 재생하여 4마디 피아노 샘플이 제대로 생성되는 것을 확인함

hierdec-mel_4bar_sample_2022-12-09_012735-000-of-005.mid
hierdec-mel_4bar_sample_2022-12-09_012735-001-of-005.mid
hierdec-mel_4bar_sample_2022-12-09_012735-002-of-005.mid
hierdec-mel_4bar_sample_2022-12-09_012735-003-of-005.mid
hierdec-mel_4bar_sample_2022-12-09_012735-004-of-005.mid

[생성된 MIDI파일 리스트]

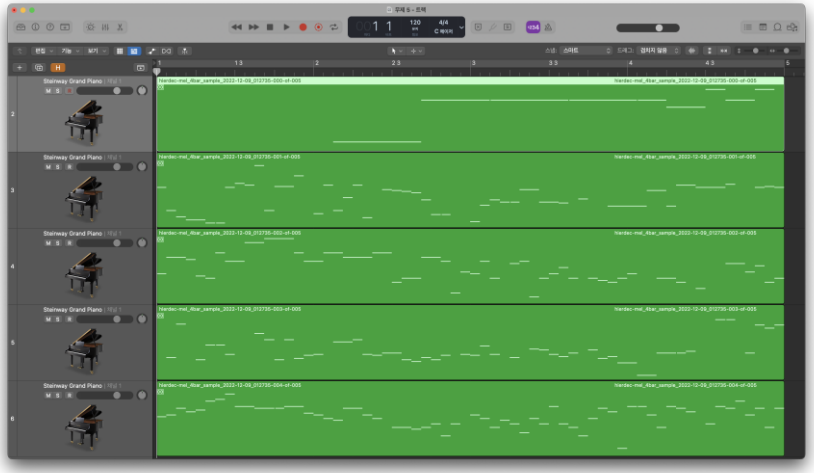

[DAW에서의 MIDI파일 로드]

❖ 실험 결과

▸ 결론

- GrooVAE 모델에 Groove dataset을 사용한 결과 MIDI파일이 정상적으로 생성되는 것을 확인함

- MusicVAE 모델에 Groove dataset을 사용한 결과 MIDI파일이 비정상적으로 생성되는 것을 확인함

- MusicVAE 모델을 사용한 실험과 동일한 조건으로 Maestro dataset을 테스트한 결과 MIDI파일의 정상적 생성을 확인함

- 따라서 현재 모델구조에서 하이퍼 파라미터나, 데이터의 양은 모델성능을 크게 저하시키는 원인이 아님을 확인

- MusicVAE 모델과 GrooVAE 모델의 차이점은 모델의 구조 차이도 있지만 Decoder의 Loss function 차이에서 성능이 갈리는 것으로 보임

- Groove 실험과 Maestro 실험에서의 차이점은 DataConverter가 다르며, 해당 알고리즘에 따라서 성능이 갈리는 것으로 보임

- 따라서 MusicVAE 모델을 활용하여 Groove Dataset에서 좋은 성능을 확보하기 위해서는
  Decoder의 Loss function의 개선이나 DataConverter 부분을 개선하는 방법이 필요해 보임

❖실험 결과에 따른 모델 개선

▸ 모델구성

- 실험 결과에 따라서 빠르게 실험 할 수 있는 DataConverter 부분을 GrooveConverter에서 DrumsConverter로 변경하여 실험 진행

- 이 부분에서 MusicVAE의 모델구조와 파라미터는 동일하게 진행함

```
CONFIG_MAP['musicvae_4bar_paper_reduceunit'] = Config(
    model=MusicVAE(lstm_models.BidirectionalLstmEncoder(),
                   lstm_models.HierarchicalLstmDecoder(
                   core_decoder = lstm_models.CategoricalLstmDecoder(),
                   level_lengths=[8, 8],
                   disable_autoregression=True)),
    hparams=merge_hparams(
        lstm_models.get_default_hparams(),
        HParams(
            batch_size=512,
            max_seq_len= 16 * 4,  # 4 bars w/ 16 steps per bar  ### 256
            z_size=256,
            enc_rnn_size=[512],    ### 2048, 2048
            dec_rnn_size=[256, 256],    ### 1024, 1024
            max_beta=0.2,
            free_bits=48,   ### 256
        )),
    note_sequence_augmenter=None,
    data_converter=data.GrooveConverter(
        split_bars=4, steps_per_quarter=4, quarters_per_bar=4,
        max_tensors_per_notesequence=20,
        pitch_classes=data.ROLAND_DRUM_PITCH_CLASSES,
        inference_pitch_classes=data.REDUCED_DRUM_PITCH_CLASSES),
    tfds_name='groove/groovae_4bar_paper',
)
```

[MusicVAE + GrooveConverter]

```
CONFIG_MAP['musicvae_4bar_paper_drumconv'] = Config(
    model=MusicVAE(lstm_models.BidirectionalLstmEncoder(),
                   lstm_models.HierarchicalLstmDecoder(
                   core_decoder = lstm_models.CategoricalLstmDecoder(),
                   level_lengths=[8, 8],
                   disable_autoregression=True)),
    hparams=merge_hparams(
        lstm_models.get_default_hparams(),
        HParams(
            batch_size=512,
            max_seq_len= 16 * 4,  # 4 bars w/ 16 steps per bar  ### 256
            z_size=256,
            enc_rnn_size=[512],    ### 2048, 2048
            dec_rnn_size=[256, 256],    ### 1024, 1024
            max_beta=0.2,
            free_bits=48,   ### 256
        )),
    note_sequence_augmenter=None,
    data_converter=data.DrumsConverter(
        slice_bars=4, steps_per_quarter=4, quarters_per_bar=4,
        max_tensors_per_notesequence=20,
        pitch_classes=data.ROLAND_DRUM_PITCH_CLASSES),
    tfds_name='groove/musicvae_4bar_paper_drumconv',
)
```

[MusicVAE + DrumsConverter]

❖실험 결과에 따른 모델 개선

▸ 모델 학습 결과 (Loss)

- Loss가 정상적으로 수렴하는 모습을 보이며, GrooVAE 모델보다 Loss가 더 빠르게 수렴하는 모습을 보임

```
2022-12-09 09:53:54.378200  {'global_step': 1600, 'loss': 74.1522}
2022-12-09 09:54:23.911575  {'global_step': 1700, 'loss': 70.050285}
2022-12-09 09:54:58.358131  {'global_step': 1800, 'loss': 67.77874}
2022-12-09 09:55:27.712484  {'global_step': 1900, 'loss': 63.473057}
2022-12-09 09:56:02.062357  {'global_step': 2000, 'loss': 59.81144}
2022-12-09 09:56:36.239632  {'global_step': 2100, 'loss': 58.829933}
2022-12-09 09:57:05.648411  {'global_step': 2200, 'loss': 55.182186}
2022-12-09 09:57:39.905466  {'global_step': 2300, 'loss': 52.64509}
2022-12-09 09:58:09.471392  {'global_step': 2400, 'loss': 49.555206}
2022-12-09 09:58:44.168635  {'global_step': 2500, 'loss': 46.774426}
2022-12-09 09:59:13.720721  {'global_step': 2600, 'loss': 46.198853}
2022-12-09 09:59:48.172193  {'global_step': 2700, 'loss': 42.103794}
2022-12-09 10:00:17.490336  {'global_step': 2800, 'loss': 40.600525}
2022-12-09 10:00:51.764039  {'global_step': 2900, 'loss': 37.019104}
2022-12-09 10:01:21.340044  {'global_step': 3000, 'loss': 35.98981}
2022-12-09 10:01:55.741228  {'global_step': 3100, 'loss': 33.767326}
2022-12-09 10:02:25.086914  {'global_step': 3200, 'loss': 31.317118}
2022-12-09 10:02:59.326642  {'global_step': 3300, 'loss': 31.525696}
2022-12-09 10:03:29.045254  {'global_step': 3400, 'loss': 28.058249}
2022-12-09 10:04:03.211414  {'global_step': 3500, 'loss': 28.542894}
2022-12-09 10:04:37.795651  {'global_step': 3600, 'loss': 24.475431}
2022-12-09 10:05:07.244037  {'global_step': 3700, 'loss': 24.38422}
```

[학습간 Loss 결과 로그]

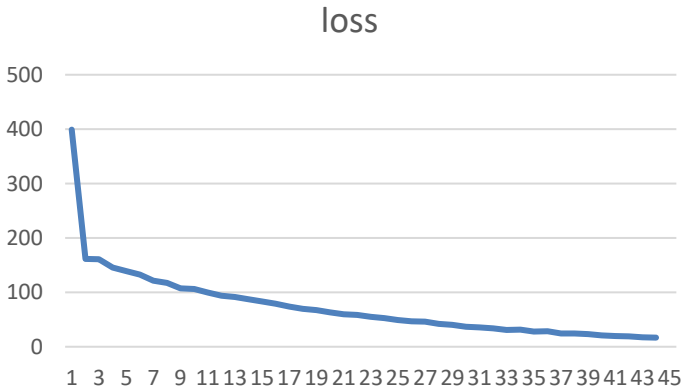

[학습간 Loss 결과 그래프]

❖실험 결과에 따른 모델 개선

▸ 모델 학습 결과 (MIDI 생성 및 재생)

- 정상적으로 미디파일이 생성되었으며, DAW에 로드 및 재생하여 4마디 드럼샘플이 제대로 생성되는 것을 확인함

- 재생시 음악적 느낌이 이전 GrooVAE 보다 향상되어 보임

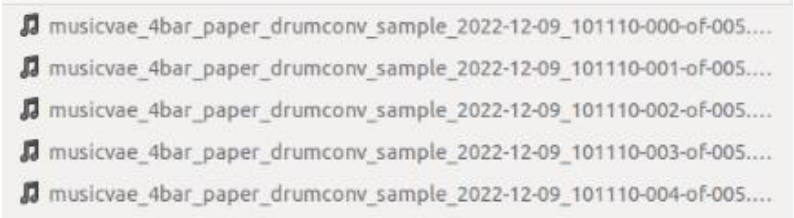

[생성된 MIDI파일 리스트]

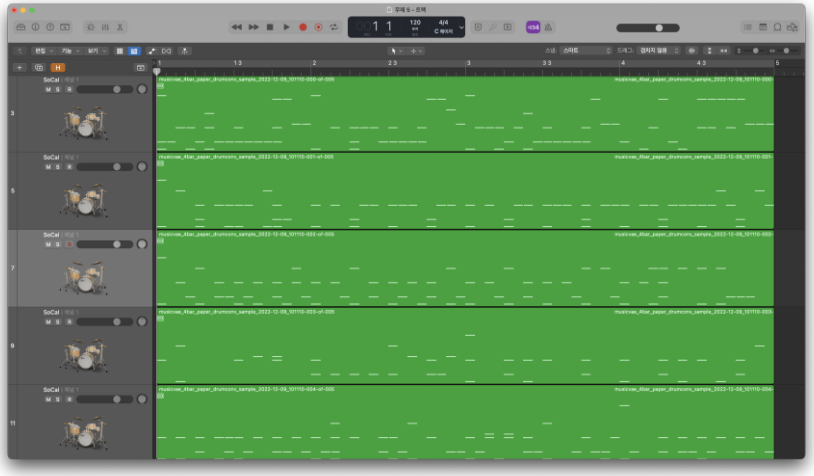

[DAW에서의 MIDI파일 로드]

❖추가 실험 결과

▸ 결론

- 기존에 실패하였던 MusicVAE 실험에서 Data Converter를 변경하여 실험

- MusicVAE + DrumsConverter 조합으로 성능 확보에 성공하였으며, 기존보다 더 좋은 Loss결과와 음악성을 보임

- GrooVAE + GrooveConverter 조합에서도 괜찮은 성능을 보였음으로 GrooveConverter 자체는 유의미한것으로 보임

- DrumsConverter와 GrooveConverter의 차이점에 대한 확인이 필요함

- MusicVAE + GrooveConverter 조합으로 성능을 내기 위해서는 Decoder의 Loss function의 개선을 통하여
  좋은성능을 이끌어낼수 있을것으로 보임

감 사 합 니 다